

Politechnika Gdańska

Wydział Elektroniki, Telekomunikacji i Informatyki

Katedra Systemów Decyzyjnych i Robotyki

Raport Semestralny

Semestr I (zimowy 2025/2026)

Dog FACS Dataset

Utworzenie i Adnotacja Zbioru Danych
do Analizy Emocji Psów

Zespół projektowy: Danylo Lohachov (koordynator)
Anton Shkrebela
Danylo Zherzdiev
Mariia Volkova

Opiekun projektu: dr hab. inż. Michał Czubenko

Gdańsk, styczeń 2026

Spis treści

1	Założenia projektu	2
1.1	Cel główny	2
1.2	Założenia na semestr I	2
1.3	Metryki sukcesu	2
2	Zrealizowany zakres prac	2
2.1	Podsumowanie realizacji	2
2.2	Produkty końcowe semestru I	3
3	Zmiany względem pierwotnego planu	3
3.1	Zmiana 1: Architektura modelu keypoints	3
3.2	Zmiana 2: Podejście do klasyfikacji emocji	3
4	Wkład poszczególnych członków zespołu	4
4.1	Danylo Lohachov (U1) – Koordynator projektu	4
4.2	Anton Shkrebela (U2) – Specjalista AI/ML	4
4.3	Danylo Zherzdiev (U3) – Backend Developer	5
4.4	Mariia Volkova (U4) – Data Engineer	5
4.5	Podsumowanie wkładu	5
5	Proponowane oceny	6
5.1	Uzasadnienie ocen	6
6	Plany na semestr II	6

1. Założenia projektu

1.1. Cel główny

Celem projektu jest stworzenie wysokiej jakości, publicznie dostępnego zbioru danych do analizy emocji psów w formacie COCO, wspieranego przez dedykowany pipeline AI zdolny do automatycznej adnotacji.

1.2. Założenia na semestr I

Na semestr I zaplanowano następujące cele:

1. **Analiza i badania** – analiza systemu DogFACS, formatu COCO, istniejących zbiorów danych i modeli SOTA
2. **Model detekcji psów** – fine-tuning YOLOv8 do wykrywania psów na obrazach (cel: mAP > 85%)
3. **Model klasyfikacji ras** – fine-tuning EfficientNet do rozpoznawania ras psów (cel: Top-5 accuracy > 80%)
4. **Model punktów kluczowych** – detekcja punktów kluczowych pyska psa (cel: PCK@0.1 > 75%)
5. **Klasyfikator emocji** – mapowanie punktów kluczowych na emocje DogFACS (cel: accuracy > 70%)
6. **Pipeline inference** – integracja wszystkich modeli w zunifikowany pipeline
7. **Aplikacja demo** – interfejs webowy (Streamlit) do wizualizacji wyników
8. **Dokumentacja** – DPP, DTP, dokumentacja techniczna

1.3. Metryki sukcesu

Model	Metryka	Wymagane minimum
Detekcja BBox	mAP@0.5	> 85%
Klasyfikacja ras	Top-5 accuracy	> 80%
Detekcja keypoints	PCK@0.1	> 75%
Klasyfikacja emocji	Accuracy	> 70%

Tabela 1: Założone metryki jakości modeli AI

2. Zrealizowany zakres prac

2.1. Podsumowanie realizacji

Wszystkie główne założenia na semestr I zostały zrealizowane. Poniżej przedstawiono szczegółowy status każdego zadania:

Zadanie	Status	Wynik	Cel
Analiza DogFACS i COCO	Zrealizowane	–	–
Model detekcji psów (YOLOv8m)	Zrealizowane	87.3%	> 85%
Model klasyfikacji ras (EfficientNet-B4)	Zrealizowane	82.1%	> 80%
Model keypoints (SimpleBaseline)	Zrealizowane	76.8%	> 75%
Klasyfikator emocji (Rule-based)	Zrealizowane	71.5%	> 70%
Pipeline inference	Zrealizowane	–	–
Aplikacja demo (Streamlit)	Zrealizowane	–	–
Dokumentacja DPP, DTP	Zrealizowane	–	–

Tabela 2: Status realizacji zadań semestru I

2.2. Produkty końcowe semestru I

- **Pipeline AI** – działający system przetwarzający obrazy end-to-end:
 - Detekcja psów → Klasyfikacja rasy → Detekcja keypoints → Klasyfikacja emocji
 - Wyjście w formacie COCO JSON
- **Aplikacja demo** – interfejs Streamlit do wgrywania obrazów i wizualizacji wyników
- **Repozytorium GitHub** – kod źródłowy z CI/CD
- **Dokumentacja** – DPP, DTP, dokumentacja techniczna w LaTeX

3. Zmiany względem pierwotnego planu

W trakcie realizacji projektu wprowadzono dwie zmiany architektoniczne:

3.1. Zmiana 1: Architektura modelu keypoints

- **Plan:** HRNet (High-Resolution Network)
- **Realizacja:** SimpleBaseline
- **Powód:** Lepsza dostępność pretrenowanych wag, prostsza implementacja przy porównywalnej jakości. HRNet wymagał znacznie więcej zasobów obliczeniowych i czasu na fine-tuning.
- **Wynik:** Model SimpleBaseline osiągnął $PCK@0.1 = 76.8\%$, przekraczając założony cel ($> 75\%$).

3.2. Zmiana 2: Podejście do klasyfikacji emocji

- **Plan:** Trenowany model ML (sieć neuronowa)
- **Realizacja:** Rule-based classifier oparty na DogFACS

- **Powód:** Brak odpowiedniego zbioru treningowego z etykietami emocji psów. Istniejące datasey nie zawierają adnotacji emocji zgodnych z DogFACS.
- **Wynik:** Klasyfikator rule-based mapuje wykryte Action Units na kategorie emocji z $\text{accuracy} = 71.5\%$, przekraczając założony cel ($> 70\%$).

4. Wkład poszczególnych członków zespołu

4.1. Danylo Lohachov (U1) – Koordynator projektu

- Koordynacja prac zespołu i harmonogramu
- Prowadzenie dokumentacji projektowej (DPP, DTP)
- Rozwój aplikacji demonstracyjnej (Streamlit)
- Zarządzanie repozytorium GitHub i Linear
- Kontrola jakości (code review)

Główne osiągnięcia:

- Działająca aplikacja demo Streamlit
- Kompletna dokumentacja projektowa
- Skuteczna koordynacja 4-osobowego zespołu

4.2. Anton Shkrebela (U2) – Specjalista AI/ML

- Analiza i wybór architektury modelu keypoints
- Implementacja i trenowanie modelu detekcji punktów kluczowych
- Implementacja systemu DogFACS (11 Action Units)
- Opracowanie klasyfikatora emocji (rule-based)
- Ewaluacja i optymalizacja modeli

Główne osiągnięcia:

- Model keypoints z $\text{PCK@0.1} = 76.8\%$
- Działający klasyfikator emocji z $\text{accuracy} = 71.5\%$
- Kompletna implementacja systemu DogFACS

4.3. Danylo Zherzdiev (U3) – Backend Developer

- Fine-tuning modelu YOLOv8 do detekcji psów
- Fine-tuning modelu EfficientNet do klasyfikacji ras
- Integracja wszystkich modeli w zunifikowany pipeline
- Implementacja formatu COCO z rozszerzeniami DogFACS
- Optymalizacja wydajności pipeline'u

Główne osiągnięcia:

- Model detekcji z mAP = 87.3%
- Model klasyfikacji ras z Top-5 accuracy = 82.1%
- Działający pipeline przetwarzający obrazy end-to-end

4.4. Mariia Volkova (U4) – Data Engineer

- Konfiguracja środowiska deweloperskiego
- Przygotowanie i przetwarzanie zbiorów danych treningowych
- Analiza istniejących datasetów (HuggingFace, Kaggle)
- Przygotowanie skryptów do pobierania i przetwarzania danych
- Wsparcie w testowaniu modeli

Główne osiągnięcia:

- Skonfigurowane środowisko deweloperskie
- Przygotowane dane treningowe dla wszystkich modeli
- Skrypty do ekstrakcji klatek z filmów

4.5. Podsumowanie wkładu

Osoba	Główny obszar odpowiedzialności	Wkład
Danylo Lohachov	Koordinacja, dokumentacja, frontend	30%
Anton Shkrebela	Modele keypoints i emocji, DogFACS	30%
Danylo Zherzdiev	Modele BBox i ras, pipeline, COCO	20%
Mariia Volkova	Środowisko, dane, wsparcie	20%

Tabela 3: Podział wkładu w projekcie

Osoba	Ocena	Uzasadnienie
Danylo Lohachov	5.0	Skuteczna koordynacja projektu, terminowa realizacja wszystkich zadań, kompletna dokumentacja, działająca aplikacja demo
Anton Shkrebela	5.0	Samodzielna implementacja modeli keypoints i emocji, osiągnięcie założonych metryk, kreatywne rozwiązanie problemu braku danych treningowych
Danylo Zherzdiev	4.0	Implementacja modeli detekcji i klasyfikacji, integracja pipeline'u
Mariia Volkova	4.0	Konfiguracja środowiska, przygotowanie danych treningowych, wsparcie zespołu

Tabela 4: Proponowane oceny za semestr I

5. Proponowane oceny

Na podstawie zrealizowanego zakresu prac, osiągniętych wyników i zaangażowania poszczególnych członków zespołu, proponujemy następujące oceny:

5.1. Uzasadnienie ocen

1. **Wszystkie założone cele zostały zrealizowane** – każdy model AI osiągnął lub przekroczył wymagane metryki jakości
2. **Terminowość** – projekt realizowany zgodnie z harmonogramem, bez opóźnień
3. **Jakość produktów** – działający pipeline, aplikacja demo, kompletna dokumentacja
4. **Współpraca zespołowa** – równomierny podział pracy, skuteczna komunikacja, wspólne rozwiązywanie problemów
5. **Adaptacja do zmian** – elastyczne podejście do zmian architektonicznych przy zachowaniu celów projektu

6. Plany na semestr II

W semestrze II planowane są następujące prace:

1. **Zbieranie danych** – pobranie około 2500 filmów psów z YouTube
2. **Automatyczna adnotacja** – przetworzenie minimum 25 000 klatek przez pipeline AI
3. **Weryfikacja manualna** – ręczna weryfikacja 25% klatek (około 6250)
4. **Klasyfikator emocji oparty na sieci neuronowej** – zastąpienie rule-based klasyfiera modelem ML trenowanym na zebranych i zweryfikowanych danych z adnotacjami emocji

5. **Rozwój aplikacji do ręcznej adnotacji** – rozbudowa aplikacji Streamlit o pełny interfejs do manualnej adnotacji (bounding boxes, keypoints, emocje), umożliwiający weryfikację i korektę automatycznych adnotacji
6. **Finalizacja datasetu** – konwersja do formatu COCO, statystyki, dokumentacja

Dokument przygotowany przez zespół projektowy Dog FACS Dataset
Gdańsk, 29 stycznia 2026