

Dog FACS Dataset — raport z realizacji

Automatyczna anotacja mimiki psów w formacie COCO
Politechnika Gdańska, Wydział ETI — projekt grupowy, semestr 1

1. Co powstało

Celem projektu było zbudowanie zbioru danych opisującego mimikę psów według systemu DogFACS: 46 punktów kluczowych twarzy, 21 jednostek ruchu (AU) i 9 klas emocji, w formacie COCO. Powstał kompletny potok — od pobrania nagrania do gotowej anotacji — oraz stanowisko do ręcznej weryfikacji wyników przez człowieka. Oddajemy dwa artefakty:

Artefakt	Pary	Klatki	Etykieta AU
Zbiór zweryfikowany przez człowieka	518	825	ocena człowieka
Zbiór pełny	9 519	12 238	model, precyzja 32.7%

Każda próbka to PARA klatek: spoczynkowa i szczytowa. Jednostki ruchu są z definicji różnicą względem spoczynku, więc pojedyncza klatka nie niesie informacji o AU. Zbiór obejmuje 79 ras rozpoznanych przez klasyfikator. Zespół obejrzał i ocenił 613 par, z czego 84 odrzucił jako nienadające się do kodowania mimiki; 11 par oceniono rozbieżnie i są oznaczone jako sporne.

Rozkład emocji w podzbiorze zweryfikowanym przez człowieka (ocena anotatora, nie etykieta z nazwy katalogu):

Emocja	Par
neutral	200
relaxed	183
sad	55
happy	33
surprise	33
fearful	5
angry	5
submission	3
pain	1

Przewaga stanów spokojnych jest cechą materiału źródłowego: nagrania psów w otwartych źródłach to w większości sceny spokojne. Stany silne (ból, strach, agresja) są rzadkie i pozostają najłabiej reprezentowane.

2. Skala przetwarzania

Przetworzyliśmy 4553 nagrań o łącznej objętości około 4.9 GB. Każde przeszło pełny potok: detekcja psa, śledzenie, kadrowanie mordy, 46 punktów kluczowych, rasa, jednostki ruchu i emocja. Poniższa tabela pokazuje, ile materiału przeżywa kolejne etapy — i to jest najważniejsza liczba w całym raporcie, bo tłumaczy rozmiar zbioru.

Etap	Ilość	Przechodzi dalej
Nagrania pobrane i przetworzone	4 553	—
Nagrania, z których cokolwiek powstało	1 904	41.8%
Klatki wybrane przez modele	25 447	—
Kandydaci na klatki szczytowe	18 929	—
Pary po bramce jakości	9 519	50.3%
Pary ocenione ręcznie przez zespół	518	5.4%

Z 4553 nagrań aż 2649 (58.2%) nie dało ani jednej pary nadającej się do oceny. Nie znaczy to, że przetwarzanie się nie udało — znaczy, że na tych nagraniach nie ma ujęcia psiej mordy dość dużego i dość spokojnego, żeby zmierzyć na nim mimikę.

3. Dlaczego odpadła połowa materiału

Bramka jakości odrzuca klatkę, na której pomiar mimiki byłby zmyśleniem. Rozkład powodów nie zostawia wątpliwości, gdzie leży ograniczenie:

Powód odrzucenia	Klatek	Udział
morda za mała do weryfikacji	14 290	76.5%
za dużo niepewnych punktów kluczowych	3 103	16.6%
profil lub obrót głowy	825	4.4%
punkty postawione byle gdzie	344	1.8%
punkty rozdzielone między dwa psy	128	0.7%

Liczby dotyczą pojedynczych klatek, a para odpada, gdy zawiedzie choćby jedna z dwóch — dlatego suma powodów przewyższa liczbę odrzuconych par. Część materiału odrzuconego automatycznie wróciła później do zbioru po ręcznym przejrzeniu przez zespół.

Trzy czwarte odrzuceń to jeden powód: morda w kadrze jest za mała. Jednostki ruchu DogFACS to przesunięcia rzędu kilku pikseli — zmarszczenie nosa, uniesienie wargi, obrót ucha. Na mordzie o szerokości 40 pikseli taki ruch tonie w niepewności samego detektora punktów. To ograniczenie materiału, nie potoku: dostępne nagrania psów to w większości ujęcia całej sylwetki, plany ogólne i materiał z mediów społecznościowych kręcony z ręki, gdzie pysk zajmuje ułamek kadru i rzadko jest zwrócony do obiektywu.

4. Jakość poszczególnych modeli

Potok składa się z pięciu modeli uruchamianych po kolei. Ich jakość jest bardzo różna i to rozwarstwienie jest istotnym wynikiem samym w sobie:

Zadanie	Architektura	Jakość	Uwagi
Detekcja psa	YOLOv8m	—	gotowe wagi, bez dotrenowania
Klasyfikacja rasy	EfficientNet-B4	Top-1 91.5%	120 ras
Detekcja mordy	YOLOv8n	mAP50 0.99	kadrowanie przed punktami
Punkty kluczowe	HRNet-W48	NME 0.091 / PCK 0.748	46 punktów DogFLW
Jednostki ruchu (AU)	regresja na geometrii	precyzja 32.7%	21 AU DogFACS
Emocje	reguły na AU	brak metryki	9 klas, bez danych odniesienia

Zadania rozpoznawania obiektu — gdzie jest pies, gdzie mordą, jaka rasa — są rozwiązywane dobrze. Trudność zaczyna się przy mimice.

5. Jednostki ruchu — najtrudniejsza część

Wyjściowo AU wyznaczaliśmy regułami geometrycznymi: każda jednostka to jedna odległość między punktami, porównana ze wspólnym progiem. Zmierzenie tych reguł wobec ocen człowieka pokazało, że dają precyzję 5% — czyli dziewiętnaście sygnałów na dwadzieścia jest fałszywych. Zastąpiliśmy je modelem uczonym z przesunięcia wszystkich 46 punktów naraz. Wszystkie wyniki poniżej pochodzą ze sprawdzianu krzyżowego z podziałem po nagraniach, w którym próg decyzyjny dobierany jest wyłącznie na części uczącej:

Metoda	Precyzja	Pokrycie	F1
Reguły geometryczne (stan wyjściowy)	5.0%	40.5%	8.9%
Reguły + szumowy gejt	5.7%	29.3%	9.5%
Reguły + próg dobrany na każde AU	10.7%	38.5%	16.7%
Model uczony z pełnej geometrii	26.8%	22.5%	24.5%
Model + spójny standard anotacji	32.7%	26.3%	29.1%

Precyzja wzrosła sześciokrotnie, z 5.0% na 32.7%. Warto zaznaczyć, skąd wziął się ostatni krok: nie z większej sieci, lecz z ODRZUCENIA części etykiet. Członkowie zespołu stosowali różne progi tego, co uznać za aktywację — udział komórek oznaczonych jako aktywne wahał się od 0.17% do 5.4%. Uczenie na 273 parach o spójnym standardzie wypadło lepiej niż na wszystkich dostępnych.

Jakość mocno zależy od jednostki. Najlepiej mierzalne są ruchy pyska, bo są duże i wyraźne geometrycznie; ruchy uszu i górnej części twarzy pozostają poza zasięgiem obecnych punktów kluczowych:

Jednostka ruchu	Potwierdzeń	Precyzja	Pokrycie
AU25 — rozchylenie warg	35	52.6%	57.1%
AU116 — obniżenie wargi dolnej	17	44.4%	47.1%
AD19 — pokazanie języka	35	41.0%	45.7%
AU27 — rozciągnięcie pyska	24	37.0%	41.7%
AU26 — opuszczenie żuchwy	20	35.3%	30.0%
AU118 — wysunięcie warg	12	60.0%	25.0%

Cztery jednostki (AD33, AD35, EAD101, EAD102) nie zostały potwierdzone przez człowieka ani razu — nie da się ich zatem ani nauczyć, ani ocenić.

6. Ograniczenia, które ukształtowały wynik

Materiał. Nie istnieje gotowy zbiór nagrań psów nadający się do kodowania DogFACS. Zbieraliśmy go sami z materiału stockowego, serwisów wideo i archiwum udostępnionego na dysku współdzielonym. Zmierzona wydajność takiego materiału jest niska: z 4553 nagrań użyteczne okazało się co drugie, a bramka jakości odrzuca połowę tego, co z nich zostało. Zwiększenie zbioru wymaga nie tyle więcej nagrań, ile nagrań INNEGO rodzaju — zbliżeń psiej mordy zwróconej do obiektywu. Takich w otwartych źródłach jest niewiele.

Moc obliczeniowa. Pracowaliśmy na komputerach osobistych, bez dostępu do klastra ani do kart graficznych klasy serwerowej. Potok uruchamia na każde nagranie pięć sieci neuronowych po kolei, a każdy proces roboczy zajmuje około 1,3 GB pamięci na same wagi modeli, do czego dochodzi bufor pełnych klatek. Ogranicza nas pamięć, nie procesor: liczba równoległych procesów, którą maszyna utrzyma, wyznacza tempo całego przetwarzania. Pobieranie materiału ma własne ograniczenie — anonimowy dostęp do dysku współdzielonego przyjmuje kilkadziesiąt plików dziennie, więc sam transfer materiału był rozłożony na wiele podejść.

Powtarzalność etykiety. Najpoważniejsze ograniczenie nie jest ani sprzętowe, ani materiałowe. Na parach ocenionych niezależnie przez dwie osoby zgodność co do tego, które AU są aktywne, wynosi 7.4%, a współczynnik kappa Cohena 0.132 — niewiele powyżej losu. Zgodność co do tego, czy para w ogóle nadaje się do oceny, jest wysoka (90.2%), podobnie jak co do emocji (62.9%); rozjeżdżają się wyłącznie jednostki ruchu. Dopóki ludzie nie kodują ich tak samo, żaden model nie może zostać rzetelnie zmierzony — bo nie ma stabilnego punktu odniesienia.

7. Wnioski

Potok działa i zbiór istnieje. Powstało 9 519 par klatek z pełną anotacją geometryczną, w tym 518 zweryfikowanych przez człowieka. Rozpoznawanie psa, mordy i rasy działa na poziomie użytkowym.

Wąskim gardłem AU okazały się reguły, a nie punkty kluczowe. Ten sam materiał, z którego reguły wyciągały 5% precyzji, po zastosowaniu modelu uczonego daje 33%. Informacja była w danych przez cały czas — poprzednia metoda jej nie wykorzystywała. To najważniejszy wniosek techniczny projektu.

Dalszy postęp wymaga lepszej etykiety, nie lepszego modelu. Przy zgodności między anotatorami na poziomie 7.4% model o precyzji 33% zbliża się do granicy powtarzalności samego zjawiska. Kolejnym krokiem jest pisemna instrukcja kodowania dla dziewięciu mierzalnych jednostek i sesja kalibracyjna zespołu na wspólnym podzbiorze par — dopiero potem ma sens rozbudowa modelu.

Uczciwość etykiet. W zbiorze rozróżniamy trzy źródła oceny: człowiek, model i reguły; mówi o tym pole `label_source`. Etykieta automatyczna jest wyraźnie oznaczona jako słaba — przy precyzji 33% dwie aktywacje na trzy są błędne. Nie podajemy jej jako prawdy, bo zbiór z ukrytym błędem tej skali byłby gorszy niż brak zbioru.

Wszystkie liczby w raporcie pochodzą z pomiarów na repozytorium projektu i dają się odtworzyć poleceniami opisanymi w dokumentacji technicznej (`eval_au_rules`, `train_au_model`, `build_full_dataset`).